

¿Reflejan los Sectores de Wall Street el Riesgo Real?

Clustering Espectral y Detección de Comunidades en Redes Complejas

Miguel Ignacio Arias Meriño Jorge Ignacio Moreno Farías

Álgebra Lineal y Optimización para Data Science

Red de Correlación Bursátil del S&P 500 (2014–2024)

Octubre 2026

El Enigma: ¿Etiquetas Burocráticas o Riesgo Sistémico?

Taxonomía GICS Tradicional

- Clasificación estática basada en productos y balances contables.
- Cuatro sectores bajo estudio: **Tecnología, Finanzas, Salud y Energía.**
- **Premisa:** Las empresas de un mismo sector co-varían armónicamente.

La Falla en Escenarios de Crisis

El contagio de liquidez y volatilidad ignora las etiquetas administrativas.

Pregunta Central de Investigación

¿Es capaz el clustering espectral de reconstruir a ciegas las comunidades estructurales de riesgo en el S&P 500, basándose puramente en fluctuaciones de precios y sin etiquetas previas?

¿Por qué el enfoque espectral?

- Resuelve la maldición de la dimensionalidad.
- Filtra el ruido estocástico del mercado bursátil.

Construcción y Preparación del Grafo Bursátil

Pipeline Metodológico:

- 1 **Series Temporales:** 10 años de cotizaciones diarias (2014–2024) vía Yahoo Finance ($T = 2,515$ ruedas).
- 2 **Universo de Inversión:** 160 activos iniciales; filtrado estricto de NaNs y deslistes $\rightarrow n = 141$ **nodos válidos**.
- 3 **Pesos (W):** Retornos porcentuales diarios y matriz de correlación de Pearson $\rho_{ij} \in [-1, 1]$.

Decisiones Topológicas Clave:

- **Sin auto-bucles:** $\text{diag}(A) = 0$ (evita redundancia estructural).
- **Umbral de similitud:** $A_{ij} = \rho_{ij}$ si $\rho_{ij} \geq 0,40$, sino 0.

Diagnóstico Estructural de la Red

- **Nodos finales (n):** 141
- **Aristas ponderadas ($|E|$):** 1.984
- **Grado promedio ($\bar{d}$):** 28,14 conexiones/nodo
- **Componentes conexas (c):** 1 (Grafo conexo)
- **Nodos aislados:** 0

Garantiza una matriz de adyacencia no negativa simétrica $A = A^T$ libre de componentes triviales.

El Giro Dramático: El Colapso del Modelo Ingenuo

El Operador Laplaciano Estándar:

$$L = D - A, \quad D_{ii} = \sum_j A_{ij}$$

Forma Cuadrática (Tensión del Grafo):

$$x^\top Lx = \frac{1}{2} \sum_{i,j} A_{ij} (x_i - x_j)^2$$

El Fracaso del Corte Estándar

- Minimiza $\text{cut}(A, B) = \sum_{i \in A, j \in B} A_{ij}$.
- **Patología empírica:** Aísla nodos periféricos con grado mínimo ($d_i \approx 0$).
- **Resultado:** Un clúster con el $\sim 98\%$ del mercado y 3 clústeres triviales de 1 nodo.
- **Adjusted Rand Index (ARI):** 0,021 (Poder nulo).

Topología Resultante: Agrupamiento Trivial



Figura:

El Rescate Matemático: Normalized Cut y el Algoritmo NJW

Penalización por Volumen de Aristas

$$\text{NCut}(A_1, \dots, A_k) = \sum_{p=1}^k \frac{\text{cut}(A_p, \bar{A}_p)}{\text{vol}(A_p)}$$

“ donde $\text{vol}(A_p) = \sum_{i \in A_p} d_i$. Impide grupos diminutos.

“

Relajación Espectral (Rayleigh-Ritz):

$$L_{\text{sym}} = D^{-1/2} L D^{-1/2} = I - D^{-1/2} A D^{-1/2}$$

“

- L_{sym} es simétrica y semidefinida positiva.
- Sus autovalores están acotados:
 $0 = \lambda_1 \leq \dots \leq \lambda_n \leq 2$.

El Paso Crítico: Normalización de Filas (NJW)

Sea $U = [v_1, \dots, v_k] \in \mathbb{R}^{n \times k}$ con los primeros k autovectores. Se construye $T \in \mathbb{R}^{n \times k}$ mediante:

$$T_{ij} = \frac{U_{ij}}{\left(\sum_{l=1}^k U_{il}^2 \right)^{1/2}}$$

Propiedad Geométrica Fundamental:

- Cada nodo se proyecta a la esfera unitaria:
 $\|T_{i,\cdot}\|_2 = 1$.
- Elimina el sesgo de escala por el grado d_i del nodo en K -Means.

La Señal en el Espectro: La Heurística del Eigengap

Propiedades del Espectro de L_{sym} :

- $\lambda_1 = 0$ con multiplicidad algebraica $c = 1$ (red conexa).
- $\lambda_2 > 0$: Conectividad algebraica y cota de Fiedler.

Criterio Objetivo de Elección (k)

Se busca maximizar el salto espectral relativo:

$$\Delta_k = \lambda_{k+1} - \lambda_k$$

- $\lambda_1, \lambda_2, \lambda_3, \lambda_4$ crecen suavemente.
- Quiebre abrupto en $\lambda_5 - \lambda_4$ (**Eigengap**).
- **Veredicto matemático:** Fijar $k = 4$.




Figura:

Espectro del Laplaciano: Los datos piden 4 grupos sin forzar la hipótesis.

El Espacio Latente: Mapeo Previo al Clustering

De Nodos a Coordenadas Geométricas:

- Cada fila de T ubica al activo en $\mathbb{R}^4$.
- Eje X: **Vector de Fiedler** (v_2) $\rightarrow$ Bipartición primaria de la red.
- Eje Y: **Autovector 3** (v_3) $\rightarrow$ Segunda dirección de máxima varianza espectral.

Desacoplamiento sin Supervisión

Sin ejecutar K -Means aún, los sectores se auto-organizan en cuadrantes separados:

- **Energía:** Rayo radial aislado.
- **Finanzas:** Nube compacta superior.
- **Tecnología y Salud:** Separadas ortogonalmente.




Figura:

Proyección Espectral: La distancia euclidiana refleja disimilitud topológica.

Topología de la Red: Comunidades Bursátiles Reconstruidas

Reconstrucción de la Red Compleja:

- Visualización con algoritmo de fuerzas *Spring Layout* de NetworkX.
- Cuatro colores asignados por *K*-Means sobre la representación espectral T .

Validación de Macro-Sectores:

- **Energía:** Núcleo ultra-cohesivo (ej. XOM, CVX, SLB).
- **Banca e Inversión:** Bloque compacto (JPM, GS, BAC).
- **Farmacéutica y Salud:** Sin mezcla con finanzas (PFE, JNJ, UNH).
- **Tecnología y Software:** Alta conectividad intra-cluster (AAPL, MSFT, NVDA).




Figura:

Grafo S&P 500: Separación limpia de la densidad estructural de covarianza.

Comparación Sistemática de Modelos:

Configuración	ARI $\uparrow$	NMI $\uparrow$	Silueta	Q
L No Normal.	0,021	0,045	-0,12	0,031
Shi-Malik (L_{rw})	0,812	0,774	0,46	0,442
NJW (L_{sym})	0,835	0,791	0,49	0,468
Scikit-Learn	0,835	0,791	0,49	0,468

- **Decisión 1 (L vs L_{sym}):** El salto en ARI a 0,83 demuestra la necesidad de penalizar el volumen.
- **Decisión 2 (Benchmark):** Coincidencia exacta con la librería Scikit-Learn.

Matriz de Confusión:

Sector	C1	C2	C3	C4
Finanzas	33	2	0	0
Tecnología	1	34	1	0
Salud	0	2	34	0
Energía	0	2	0	32

Altísima pureza diagonal; los cruces corresponden a activos con dinámicas híbridas.

Nodos Fronterizos: Cuando el Riesgo Desafía la Etiqueta

El Hallazgo en las Fronteras Espectrales:

- Las clasificaciones GICS ubican a FSLR (First Solar) y ENPH (Enphase Energy) en Energía o Tecnología.
- El clustering espectral las situó en la **frontera euclidiana** entre ambos mundos.

Explicación de Riesgo Real

- **Desacople del Petróleo:** Su covarianza no depende del barril de crudo tradicional (WTI/Brent).
- **Sensibilidad Tecnológica:** Dependen de tasas de descuento, semiconductores y subsidios de innovación limpia.

Conclusión del Analista Cuantitativo

El clustering espectral no cometió un error de clasificación:

Descubrió que el riesgo sistémico de la transición verde desacopla a estas empresas de su etiqueta legal histórica.



“

Limitaciones del Modelo Actual

- 1 **Correlación Estática:** Asume relaciones lineales invariantes en 10 años, ignorando quiebres en crisis.
- 2 **Sensibilidad al Umbral:** El filtro de corte ($\rho \geq 0,40$) requiere calibración empírica.
- 3 **Convexidad en K-Means:** Asume nubes hiper-esféricas tras la normalización.

Extensiones Propuestas

- 1 **Redes Temporales:** Ventanas móviles de correlación para estudiar la evolución del espectro durante pánicos de liquidez.
- 2 **Comunidades Superpuestas:** Algoritmos de factorización no negativa (NMF) sobre el Laplaciano.
- 3 **Graph Neural Networks (GNNs):** Integrar la topología del grafo con balances fundamentales contables.

Síntesis del Trabajo

- **Conexión Matemática:** El clustering espectral transforma la partición combinatoria NP-dura en una relajación continua elegante resuelta por autovectores.
- **Relevancia del Normalized Cut:** El Laplaciano normalizado simétrico (L_{sym}) con proyección de filas es indispensable en grafos reales no balanceados.
- **Aporte a Finanzas Cuantitativas:** El espectro extrae la macro-estructura latente del S&P 500 y señala empresas en transición antes que la taxonomía oficial.

Muchas gracias