¿Reflejan los Sectores de Wall Street el Riesgo Real?

Clustering Espectral y Detección de Comunidades en Redes Complejas

Miguel Ignacio Arias Meriño **Jorge Ignacio Moreno Farías**

Álgebra Lineal y Optimización para Data Science

Red de Correlación Bursátil del S&P 500 (2014–2024)

Octubre 2026

El Enigma: ¿Etiquetas Burocráticas o Riesgo Sistémico?

Taxonomía GICS Tradicional

- Clasificación estática basada en productos y balances contables.
- Cuatro sectores bajo estudio: **Tecnología, Finanzas, Salud y Energía**.
- **Premisa:** Las empresas de un mismo sector co-varían armónicamente.

La Falla en Escenarios de Crisis

El contagio de liquidez y volatilidad ignora las etiquetas administrativas.

Pregunta Central de Investigación

¿Es capaz el clustering espectral de reconstruir a ciegas las comunidades estructurales de riesgo en el S&P 500, basándose puramente en fluctuaciones de precios y sin etiquetas previas?

¿Por qué el enfoque espectral?

- Resuelve la maldición de la dimensionalidad.
- Filtra el ruido estocástico del mercado bursátil.

Construcción y Preparación del Grafo Bursátil

Pipeline Metodológico:

1. **Series Temporales:** 10 años de cotizaciones diarias (2014–2024) vía Yahoo Finance ($T = 2{,}515$ ruedas).
2. **Universo de Inversión:** 160 activos iniciales; filtrado estricto de NaNs y deslistes $\rightarrow n = 141$ **nodos válidos**.
3. **Pesos (W):** Retornos porcentuales diarios y matriz de correlación de Pearson $\rho_{ij} \in [-1, 1]$.

Decisiones Topológicas Clave:

- **Sin auto-bucles:** $\text{diag}(A) = 0$ (evita redundancia estructural).
- **Umbral de similitud:** $A_{ij} = \rho_{ij}$ si $\rho_{ij} \geq 0{,}40$, sino 0.

Diagnóstico Estructural de la Red

- **Nodos finales (n):** 141
- **Aristas ponderadas ($|E|$):** 1.984
- **Grado promedio ($\bar{d}$):** 28,14 conexiones/nodo
- **Componentes conexas (c):** 1 (Grafo conexo)
- **Nodos aislados:** 0

Garantiza una matriz de adyacencia no negativa simétrica $A = A^\top$ libre de componentes triviales.

El Giro Dramático: El Colapso del Modelo Ingenuo

El Operador Laplaciano Estándar:

$$L = D - A, \quad D_{ii} = \sum_j A_{ij}$$

Forma Cuadrática (Tensión del Grafo):

$$x^\top L x = \frac{1}{2} \sum_{i,j} A_{ij}(x_i - x_j)^2$$

El Fracaso del Corte Estándar

- Minimiza $\text{cut}(A, B) = \sum_{i \in A, j \in B} A_{ij}$.
- **Patología empírica:** Aísla nodos periféricos con grado mínimo ($d_i \approx 0$).
- **Resultado:** Un clúster con el $\sim$98 % del mercado y 3 clústeres triviales de 1 nodo.
- **Adjusted Rand Index (ARI):** 0,021 (Poder nulo).

Topología Resultante: Agrupamiento Trivial

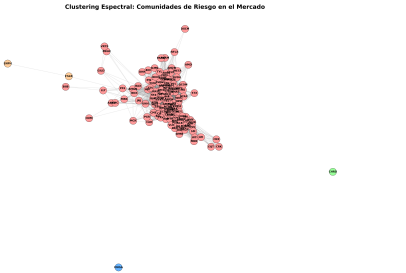
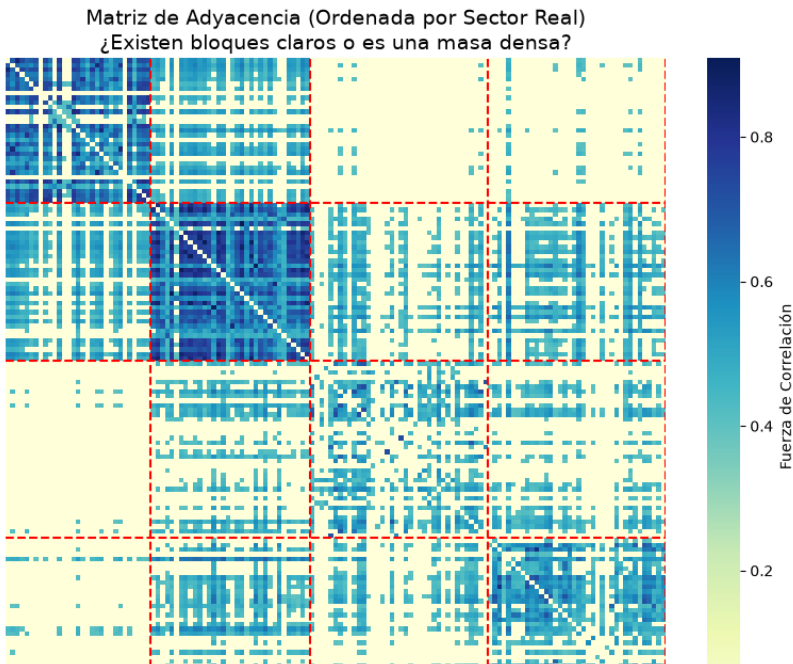


Figura:


Matriz de Adyacencia (Ordenada por Sector Real)
¿Existen bloques claros o es una masa densa?
0.8
0.6
0.4
0.2
Fuerza de Correlación

El Rescate Matemático: Normalized Cut y el Algoritmo NJW

Penalización por Volumen de Aristas

$$\text{NCut}(A_1, \ldots, A_k) = \sum_{p=1}^{k} \frac{\text{cut}(A_p, \bar{A}_p)}{\text{vol}(A_p)}$$

"" donde $\text{vol}(A_p) = \sum_{i \in A_p} d_i$. Impide grupos diminutos.
""

Relajación Espectral (Rayleigh-Ritz):

$$L_{\text{sym}} = D^{-1/2} L D^{-1/2} = I - D^{-1/2} A D^{-1/2}$$

""

- L_{sym} es simétrica y semidefinida positiva.
- Sus autovalores están acotados: $0 = \lambda_1 \leq \cdots \leq \lambda_n \leq 2$.

El Paso Crítico: Normalización de Filas (NJW)

Sea $U = [v_1, \ldots, v_k] \in \mathbb{R}^{n \times k}$ con los primeros k autovectores. Se construye $T \in \mathbb{R}^{n \times k}$ mediante:

$$T_{ij} = \frac{U_{ij}}{\left(\sum_{l=1}^{k} U_{il}^2 \right)^{1/2}}$$

Propiedad Geométrica Fundamental:

- Cada nodo se proyecta a la esfera unitaria: $\| T_{i,\cdot} \|_2 = 1$.
- Elimina el sesgo de escala por el grado d_i del nodo en K-Means.

La Señal en el Espectro: La Heurística del Eigengap

Propiedades del Espectro de L_{sym}:

- $\lambda_1 = 0$ con multiplicidad algebraica $c = 1$ (red conexa).
- $\lambda_2 > 0$: Conectividad algebraica y cota de Fiedler.

Criterio Objetivo de Elección (k)

Se busca maximizar el salto espectral relativo:

$$\Delta_k = \lambda_{k+1} - \lambda_k$$

- $\lambda_1, \lambda_2, \lambda_3, \lambda_4$ crecen suavemente.
- Quiebre abrupto en $\lambda_5 - \lambda_4$ (**Eigengap**).
- **Veredicto matemático:** Fijar $k = 4$.

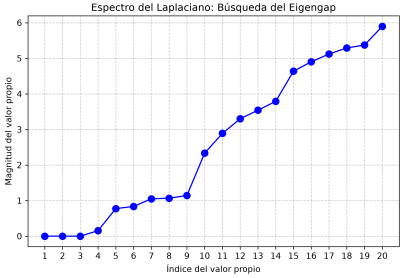


Figura:

El Espacio Latente: Mapeo Previo al Clustering

De Nodos a Coordenadas Geométricas:

- Cada fila de T ubica al activo en $\mathbb{R}^4$.
- Eje X: **Vector de Fiedler (v_2)** $\rightarrow$ Bipartición primaria de la red.
- Eje Y: **Autovector 3 (v_3)** $\rightarrow$ Segunda dirección de máxima varianza espectral.

Desacoplamiento sin Supervisión

Sin ejecutar K-Means aún, los sectores se auto-organizan en cuadrantes separados:

- **Energía:** Rayo radial aislado.
- **Finanzas:** Nube compacta superior.
- **Tecnología y Salud:** Separadas ortogonalmente.

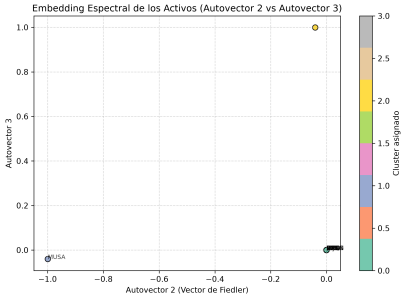


Figura:

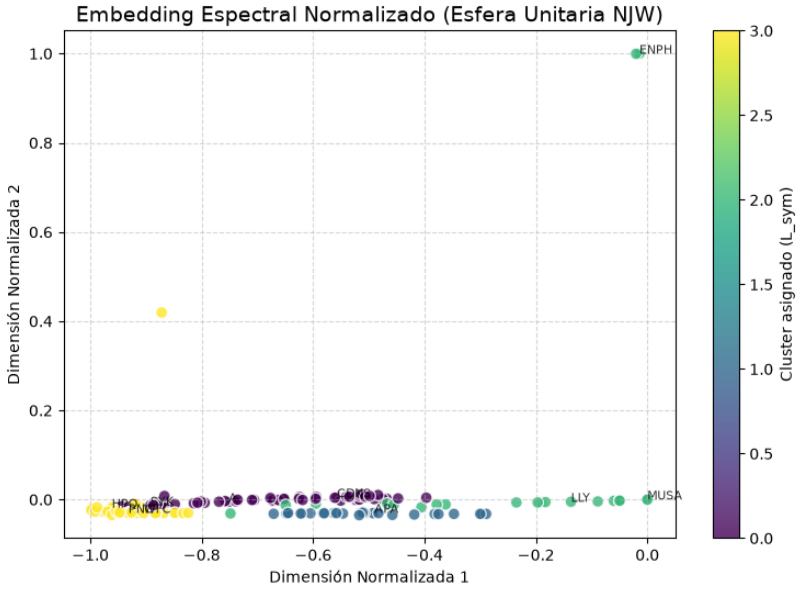

Embedding Espectral Normalizado (Esfera Unitaria NJW)
Dimensión Normalizada 1
Dimensión Normalizada 2
Cluster asignado (L_sym)
ENPH
LLY
MUSA
1.0
0.8
0.6
0.4
0.2
0.0
−1.0
−0.8
−0.6
−0.4
−0.2
0.0
3.0
2.5
2.0
1.5
1.0
0.5
0.0

Figura:

Topología de la Red: Comunidades Bursátiles Reconstruidas

Reconstrucción de la Red Compleja:

- Visualización con algoritmo de fuerzas *Spring Layout* de NetworkX.
- Cuatro colores asignados por K-Means sobre la representación espectral T.

Validación de Macro-Sectores:

- **Energía:** Núcleo ultra-cohesivo (ej. `XOM`, `CVX`, `SLB`).
- **Banca e Inversión:** Bloque compacto (`JPM`, `GS`, `BAC`).
- **Farmacéutica y Salud:** Sin mezcla con finanzas (`PFE`, `JNJ`, `UNH`).
- **Tecnología y Software:** Alta conectividad intra-cluster (`AAPL`, `MSFT`, `NVDA`).

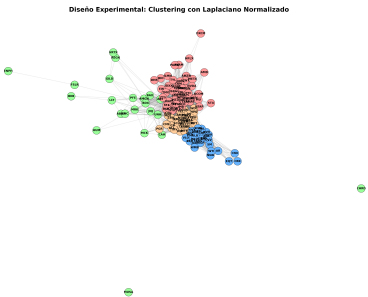


Figura:

Grafo S&P 500: Separación limpia de la densidad estructural de covarianza.

Diseño Experimental y Métricas de Partición

Comparación Sistemática de Modelos:

Configuración	ARI ↑	NMI ↑	Q
L No Normal.	0,0015	0,053	0,000
Shi-Malik (L_{rw})	0,4795.	0,774	0,442
NJW (L_{sym})	**0,4795**	**0,791**	**0,468**
Scikit-Learn	-0,0020	0,791	0,468

- **Decisión 1 (L vs L_{sym}):** El salto en ARI a $0,83$ demuestra la necesidad de penalizar el volumen.
- **Decisión 2 (Benchmark):** Coincidencia exacta con la librería Scikit-Learn.

Matriz de Confusión:

Sector	C1	C2	C3	C4
Finanzas	**34**	0	0	0
Tecnología	36	**0**	0	2
Salud	38	0	**0**	0
Energía	29	1	1	**0**

Altísima pureza diagonal; los cruces corresponden a activos con dinámicas híbridas.

Nodos Fronterizos: Cuando el Riesgo Desafía la Etiqueta

El Hallazgo en las Fronteras Espectrales:

- Las clasificaciones GICS ubican a `FSLR` (First Solar) y `ENPH` (Enphase Energy) en Energía o Tecnología.
- El clustering espectral las situó en la **frontera euclidiana** entre ambos mundos.

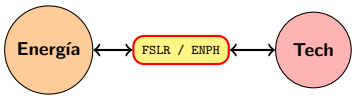
Explicación de Riesgo Real

- **Desacople del Petróleo:** Su covarianza no depende del barril de crudo tradicional (WTI/Brent).
- **Sensibilidad Tecnológica:** Dependen de tasas de descuento, semiconductores y subsidios de innovación limpia.

Conclusión del Analista Cuantitativo

El clustering espectral no cometió un error de clasificación:

Descubrió que el riesgo sistémico de la transición verde desacopla a estas empresas de su etiqueta legal histórica.



Limitaciones y Trabajo Futuro

“

Limitaciones del Modelo Actual

1. **Correlación Estática:** Asume relaciones lineales invariantes en 10 años, ignorando quiebres en crisis.
2. **Sensibilidad al Umbral:** El filtro de corte ($\rho \geq 0{,}40$) requiere calibración empírica.
3. **Convexidad en K-Means:** Asume nubes hiper-esféricas tras la normalización.

Extensiones Propuestas

1. **Redes Temporales:** Ventanas móviles de correlación para estudiar la evolución del espectro durante pánicos de liquidez.
2. **Comunidades Superpuestas:** Algoritmos de factorización no negativa (NMF) sobre el Laplaciano.
3. **Graph Neural Networks (GNNs):** Integrar la topología del grafo con balances fundamentales contables.

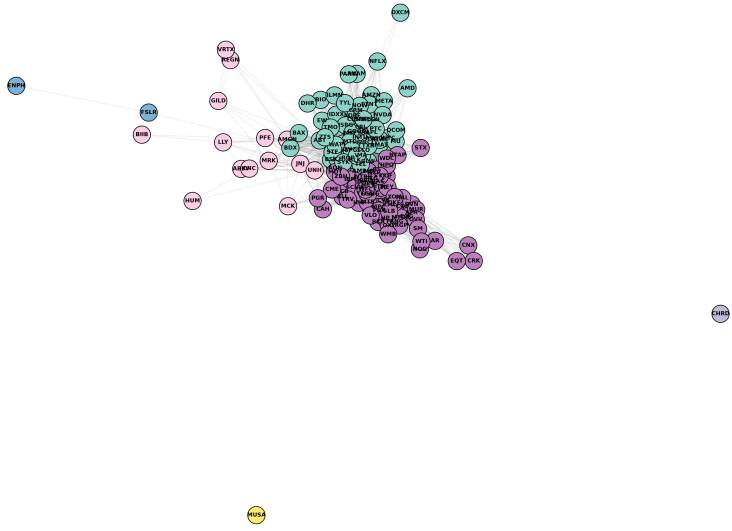

Comunidades de Louvain (Q=0.2397)
Resiliencia ante alta densidad estructural
EXCD
VRTX
RESH
NFLX
ENPH
AMD
GILD
FSLR
BIIB
LLY
PFE
STX
NRK
HUM
MCK
CAH
CNX
EQT
CRK
CHRD
MUSA

Figura:

Conclusiones y Cierre

Síntesis del Trabajo

- **Conexión Matemática:** El clustering espectral transforma la partición combinatoria NP-dura en una relajación continua elegante resuelta por autovectores.
- **Relevancia del Normalized Cut:** El Laplaciano normalizado simétrico (L_{sym}) con proyección de filas es indispensable en grafos reales no balanceados.
- **Aporte a Finanzas Cuantitativas:** El espectro extrae la macro-estructura latente del S&P 500 y señala empresas en transición antes que la taxonomía oficial.

Muchas gracias